

Andmepõhine Võimlemisoskuste Tuvastus ja Analüüs - Data Driven Gymnastics Skills Recognition and Analysis - laiendatud kokkuvõte

Allar Viinamäe

Juhendaja: Sven Nõmm

SISSEJUHATUS

Võimlemine on pika ajalooga spordiala, mis arendab füüsilist jõudu, koordineerimist, kiirust, painduvust ja graatsiat. Arenema hakkas see ala juba Vana-Kreeka ajal, mil võimlemisharjutusi kasutati näiteks leegionite ettevalmistamiseks sõjaks. Meeste võimlemine oli kavas esimestel nüüdisaja olümpiamängudel aastal 1896. Aastast 1924 on võimlemine olnud tänapäevani olümpiamängude kavas¹. Selle ajaga on võimlemises tekkinud palju harusid, näiteks iluvõimlemine, sportvõimlemine, sportakrobaatika jt. Võimlemise põhiharjutused on mõjutanud ja inspireerinud mitmeid uuemaid spordialasid. Näiteks ekstreemspordialadel tuntud pöörded üle horisontaal- ja vertikaaltelgede nõuavad harrastajalt sarnaseid füüsilisi atribuute nagu on võimlemises vaja tahasalto või pöördtega salto tegemiseks.

Võimlejad ja nende treenerid teavad, et selliste keeruliste harjutuste tegemiseks on vaja toetuda tuntud füüsikaseadustele. Nähtuseid nagu inerts, impulss, pöörlemine ja optimaalne tõukenurk tunnetab võimleja igapäevaselt ja valetehnika tunneb kogenud treener tänu kognitiivsele mustrituvastusele üpris kiiresti ära. Siiski, võimleja spordiajaloo dokumenteerimine, tehnika analüüsimine ja tagasiside andmine nõuab treeneritelt individuaalset keskendumist ja tähelepanu. Seega, harjutuste tehnika õpetamine ja korrigeerimine on olnud ja jääb ilmselt treenerite leivaks veel pikaks ajaks, sest tehnoloogilisi lahendusi, mis asendaks treenerite kogemust tänapäeval veel pole.

See magistritöö tahab aidata kaasa infotehnoloogiliste lahenduste arengule, mis aitavad treeneritel ja võimlejal automaatselt isikliku spordiajaloo dokumenteerimist ja analüüsivad harjutuste tehnikas vigu, mida võimleja ise ei tunnetata või milleks treeneritel aega pole. Magistritöö peamine eesmärk on luua lahendus, mis suudab tuvastada videost, kus atleet sooritab jada akrobaatilisi harjutusi, üksikuid harjutusi, näiteks salto taha, pöördtrelring ja trelring taha. See on oluline selleks, et analüüsida üksikutes harjutustes kõrvalekaldeid etalonsooritusest ja anda sellega tagasisidet võimlejale. Sellist lihtsustatud mudelit tagasiside andmiseks võib kujutada ette ka treenereid kasutamas kui nad jälgivad võimleja sooritust.

KONTEKST JA PROBLEEMIPÜSTITUS

Selleks, et masin saaks kaasa aidata tehnika parandamisele, peab see esmalt suutma tuvastada harjutused, mida atleet sooritab. Enne tuvastamist on aga vaja inimese liikumine digitaalselt salvestada. Inimese liikumise digitaalse salvestamise meetodid saab jämedalt liigitada kaheks: (a) **optilised meetodid** - näiteks paljudele meelelahutusmaailmast tuntud *motion capture* ja (b) **mitte-optilised meetodid** - erinevad kantavad seadmed (näiteks nutikellad), mis salvestavad keha kiirendust, rotatsiooni ja ülekoormust (*g-force*).

Digitaalse salvestamise meetodite puhul seab autor eelduse, et see oleks ka praktikas rakendatav. See on võimlemise seisukohast oluline, sest paljude levinud harjutuste kombinatsioonid nõuavad tihti peale kuni mitukümmend meetrit vaba ruumi. Harjutused nagu pöördtrelring², mida atleet kasutab horisontaalse kiiruse muundamiseks vertikaalseks kiiruseks vajavad mõned meetrid ruumi ning eeldavad, et atleedi kehale pole rakendatud väliseid piiranguid.

See välistab juhtmeterohked, piiravad ja olulist lisakaalu tekitavad mitte-optilised sensorid. Lisaks, välistavad sellised piirangud ka *motion capture* maailmas tuntud markeeritud meetodid. Näiteks on uurimuses³ tuvastatud algaja ja kogenud võimleja erinevused tehnikas ja selleks on kasutatud keha ühele küljele paigaldatud markereid. Kuigi põhjalik ja huvitav uuring, siis jätab selline meetod analüüsist välja kahe kehapoole lahknevused ning raskendatud on ka pakutud meetodi **igapäevane** ka-

sutamine. Käesoleva töö autor eeldab, et igapäevaseks analüüsiks pole võimlejad huvitatud erilisest markeeritud kostüümi selga tõmbamisest.

Oskused, mida võimleja peab valdama harjutuste sooritamiseks on näiteks oskus genereerida kõrgust (tuleneb vertikaalsest kiirusest tõuke hetkel) ja oskus õhus pöörata (tuleneb atleedi oskusest arendada ja kontrollida pöörete impulsimomenti). Selliseid ja veel teisi võimlemises vajaminevaid biomehaanilisi oskusi on varasemalt palju uuritud³⁴⁵⁶. Eelnimetatud uurimused lähenevad võimlemise biomehaanika analüüsimisele juhtumiuuringu (*case study*) meetodil ja uurivad üldiselt detailsemalt ühte kindlat harjutust. Eraldi on välja toodud ka soov kasutada interaktiivseid, lihtsalt kasutatavaid ja simulatsiooni optimeerivaid tarkvara pakette. Rõhutatud on kerget kasutatavust ja individuaalset sisendit lubavat tarkvara⁴. Just seda käesoleva magistr töö autor soovibki.

Rakenduslikust vaatenurgast lähtudes peaks pakutud biomehaanika analüüsimise lahendus olema atleedi individuaalsete parameetritega arvestav (näiteks kehaosade pikkuste suhted, mass ja riided). Sporditulemuste analüüsiks pakutav lahendus peaks olema distantsilt jälgiv, mitte-markeeritud ja kolmemõõtmelise kehaga arvestav süsteem⁷. Näitena sellisest lahendusest võib tuua magistr töö⁸, kus kasutatakse sügavussensoriga 3D kaamerat Kinect, võimlemishobusel harjutusi sooritava atleedi analüüsimiseks. Viidatud magistr töös väljatöötatud lahendus võimaldab näiteks automatiseerida pöörete lugemise, mida atleet sooritab võimlemisharjutusi tehes. Töö miinuseks (käesoleva magistr töö kontekstis) on Kinecti sügavussensori kasutamine. Sügavuspildi kasutamine suurema ruumi vajadusega võimlemisharjutuste analüüsimises võib olla vähem täpsem kui digitaalse skeleti kasutamine. Lisaks vajab sellise lahenduse kasutamine tehnikateadliku kasutaja sisendit, mida ei saa eeldada keskmisest treenerist või võimlejast.

Esimeseks uuritavaks probleemiks seab autor võimlemisharjutuste segmenteerimise ja tuvastamise. Kuna võimlemise näol on tegemist keeruliste biomehaaniliste liikumistega, siis sobib võimlemisoskuste tuvastamine hästi väljatööteldava meetodi valideerimiseks.

Teiseks probleemiks seab autor tuvastatud liigutuste tõlgendamise ja tagasiside andmise tarkvara paketi kasutajale. Väljatööteldava lahenduse saab lugeda õnnestunuks kui võimlemismaailma uurijad ja praktikud - treenerid ja atleedid hindavad lahenduse igapäevaselt kasutatavaks ja arusaadavaks.

TÖÖ ÜLESEHITUS

Autor plaanib läheneda võimlemisoskuste analüüsimise probleemile võimalikult tänapäevaste lahendustega. Viimastel aastatel on ilmunud uuringuid, kus kasutatakse inimese poosi tuvastamiseks masinõppelisi meetodeid. Näiteks avaldati aastal 2015 artikkel, kus kasutatakse inimese poosi tuvastamiseks video pealt konvolutsioonneuraalvõrke⁹. Sellised meetodid ületavad varasemad tiptasemel tehnikad oma täpsuse osas.

Hiljem on ilmunud veel täiuslikumad meetodid, mis lubavad tuvastada inimese poose ka reaajas. Näiteks kasutatakse sellist meetodit nagu *Part Affinity Fields* - sisuliselt hulk vektoreid, mis kodeerivad suuna jäseme ühest punktist teise. Iga jäset märgitakse afiinsusväljaga (ingl. *afinity field*) kehaosade vahel¹⁰. Sellist meetodit kasutab vaba lähtekoodiga tarkvara *OpenPose*¹¹. *OpenPose* lubab tuvastada ühe inimese skeletti monokaameraga filmitud videost kõrvaliste inimestega samas kaadris. See võimaldab tuvastada atleedi skeletti ka keskkonnas, kus liiguvad taustal ringi teised inimesed (tavapärane vaatepilt võimlemiskeskustes).

Käesoleva töö autor loodab ehitada praktiliselt kasutatava lahenduse toetudes eelnevatele töödele poosi hindamise *pose estimation* valdkonnas. Lisaks alternatiividega tutvumisele, plaanib autor kasutada võimlemisoskuste digitaalseks salvestamiseks vabavaralist tarkvara *OpenPose*. Poosi hindamist teostavateks alternatiivideks peale *OpenPose*'i on veel näiteks *PoseNet*¹² ja *wrnchAI*¹³. Lõpliku otsuse poosi hindamise komponendi kasutamiseks teeb autor peale põhjalikumalt alternatiividega tutvumist ja tarkvara katsetamist akrobaatiliste elementide tuvastamiseks.

Magistr töö praktilise osa üldine ülesehitus kulgeb järgnevalt:

1. Esmalt plaanib autor filmida nii algajaid kui ka kogenud atleete sooritamas võimlemisoskusi.
2. Seejärel, kasutab autor vabatarkvaralist lahendust OpenPose (või mõnda muud alternatiivi) atleedi skeleti digitaalseks salvestamiseks.
3. Skeleti digitaalsest salvestusest tuleb vajalikud andmed ekstraheerida ja kasutada neid harjutuse **tuvastusalgoritmi** sisenditena. Tuvastusalgoritm koosneb masinõppel põhinevatel meetoditel, kuid täpsem algoritmi arhitektuur selgub töö käigus. Tuvastusalgoritmi täpsuseks seab autor 80%, sest eelnevad tuvastustulemused antud valdkonnas puuduvad.
4. Tuvastusalgoritmi tulemused tuleb seejärel tõlgendada. Lisaks, võimlemisoskuste paremaks interpreteerimiseks plaanib autor rakendada **keskmise trajektoori** meetodit¹⁴. Kaalutakse ka alternatiivseid meetodeid.
5. Väljatöötatud lahendus pakutakse katsetamiseks võimlemistreeneritele ja võimlejatele. Kui lahendus läbib valitud valideerimiskriteeriumid, siis võib lahenduse lugeda õnnestunuks.
6. Viimase osana arutleb autor tulemuste üle ja pakub võimalusi lahenduse täiendamiseks.

Valmis magistritöö tuumaks on uurida, millised digitaalselt salvestatud liikumise parameetrid ja millised masinõppelised mudelid saavutavad maksimaalse täpsusega tulemused võimlemisharjutuste tuvastamisel. Tuvastusalgoritmi valikul alustatakse klassikaliste masinõppeliste meetoditega (k-means, Decision Trees) ning lisaks kaalutakse ka sügavate tehiseärvivõrkude rakendamist. Valitava algoritmi valik sõltub andmetest, mis kogutakse pärast liikumiste digitaalset salvestamist.

VALIDEERIMINE

Täpsemad meetodid võimlemisharjutuste tuvastusalgoritmi valideerimiseks selguvad töö käigus. Lihtsamate võimlemisharjutuste valideerimisel on üheks võimaluseks võrrelda OpenPose'iga salvestatud parameetrite ja valitud tuvastusalgoritmi tulemusi mõne olemasoleva ja kättesaadava liikumise salvestamise vahendi (motion capture) tulemustega. Raskemate ja rohkem ruumi vajavate võimlemisharjutuste tuvastuste valideerimiseks saab kasutada tuvastusalgoritmi tulemuste ja video abil kasutaja manuaalsete sisendite võrdlemist. See tähendab, et kui kasutaja tuvastatud võimlemisharjutus kattub tuvastusalgoritmi poolt pakutud tulemusega, siis võib tuvastuse lugeda õnnestunuks.

Valmis magistritöö põhipanuse seisneb masinõppe mudelite treenimiseks sobivas formaadis andmekogu loomisest ja akrobaatiliste elementide tuvastusalgoritmi arhitektuuri kirjeldusest.

REFERENCES

1. A History of Gymnastics: From Ancient Greece to Modern Times, Michael Strauss <https://www.scholastic.com/teachers/articles/teaching-content/history-gymnastics-ancient-greece-modern-times/> (accessed Nov 2019)
2. Roundoff <https://en.wikipedia.org/wiki/Roundoff> (accessed Nov 2019)
3. Burgess, R., & Noffal, G. (2001). Kinematic analysis of the back salto take-off in a tumbling series: advanced vs. beginner techniques. In ISBS-Conference Proceedings Archive (Vol. 1, No. 1).
4. Prassas, S., Kwon, Y. H., & Sands, W. A. (2006). Biomechanical research in artistic gymnastics: a review. *Sports Biomechanics*, 5(2), 261-291.
5. Penitente, G., Merni, F., & Sands, A. (2011). Kinematic analysis of the centre of mass in the back handspring: A case study. *Gym Coach*, 4, 1-11.
6. Faggiani, F., McRobert, A. P., & Knowles, Z. (2012). Developing pre-performance routines for acrobatic gymnastics: a case study with a youth tumbling gymnast. *Science of Gymnastics Journal*, 4(2).
7. Alderson, J. (2015). A markerless motion capture technique for sport performance analysis and injury prevention: Toward a 'big data', machine learning future. *Journal of Science and Medicine in Sport*, 19, e79.
8. Reily, B. J. (2016). Human activity recognition and gymnastics analysis through depth imagery (Doctoral dissertation, Colorado School of Mines. Arthur Lakes Library).

9. Pfister, T., Charles, J., & Zisserman, A. (2015). Flowing convnets for human pose estimation in videos. In Proceedings of the IEEE International Conference on Computer Vision (pp. 1913-1921).
10. Cao, Z., Simon, T., Wei, S. E., & Sheikh, Y. (2017). Realtime multi-person 2d pose estimation using part affinity fields. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (pp. 7291-7299).
11. Cao, Z., Hidalgo, G., Simon, T., Wei, S. E., & Sheikh, Y. (2018). OpenPose: realtime multi-person 2D pose estimation using Part Affinity Fields. arXiv preprint arXiv:1812.08008.
12. <https://github.com/tensorflow/tfjs-models/tree/master/posenet>
13. <https://wrnch.ai/technology/>
14. Nömm, S., Toomela, A., & Gaichenja, I. (2017, April). Towards the Notion of Average Trajectory of the Repeating Motion of Human Limbs. In Asian Conference on Intelligent Information and Database Systems (pp. 582-591). Springer, Cham.